

# Step Report: D-1v2 — Enriched Data Analysis

**Projeto:** Clawkeeper **Dia/Etapa:** D-1 revisado — Dados enriquecidos (2000 PRs + additions/deletions)  
**Timestamp:** 2026-02-17T10:25:00-03:00 **Duração:** ~20 min

## O que fiz

- 1. Ampliei histórico: 500 → **2000 PRs** (20 páginas API, unique by number)
- 2. Enriqueci 200 PRs (100 merged + 100 closed) com additions/deletions/changedFiles/reviews
- 3. Analisei merge rates por: size, component, channel, contributor type, author
- 4. Busquei score numérico do Greptile (1-5) — não encontrado nos dados atuais
- 5. Instalei e autentiquei `gh CLI` (tiuitobot)

## O que encontrei

### Merge Rate Real (N=2000): 25.5%

- **Amostra de 500 dava 39%** — viés de recência severo. Os dados mais antigos têm merge rate menor.
- 509 merged, 1491 closed sem merge.

### Size → Merge Rate (confirmado, N maior)

Size	Merge Rate	N	Delta vs N=500
XS	30%	457	-3pp
S	<b>46%</b>	373	-4pp
M	<b>43%</b>	203	-12pp
L	<b>47%</b>	106	-8pp
XL	<b>13%</b>	162	-3pp

Pattern mantém: sweet spot S-L, XL quase auto-rejeição. M caiu mais que esperado (de 55% pra 43%).

### Contributor Type → Merge Rate (CORREÇÃO IMPORTANTE)

Tipo	Merge Rate	N
maintainer	<b>88%</b>	110
trusted-contributor	<b>60%</b>	96
experienced-contributor	<b>50%</b>	99
sem label de contributor	~15-20%	~1700

⚠ **Com N=500, trusted-contributor dava 34% — FALSO.** Com N=2000, dá 60%. A amostra menor estava enviesada. Hierarquia é clara e forte: maintainer > trusted > experienced > unknown. Preditor poderoso pro logit.

### Component → Merge Rate

Component	Merge Rate	N
docs	<b>24%</b>	295
agents	20%	770
gateway	20%	390
cli	16%	218
commands	16%	280
app: web-ui	<b>12%</b>	228

web-ui é a área mais difícil de entrar. docs a mais fácil (faz sentido — menor risco).

### Channel → Merge Rate

Channel	Merge Rate	N
telegram	<b>18%</b>	259
discord	16%	266
slack	12%	185
whatsapp-web	9%	175
mattermost	8%	89
signal	<b>6%</b>	138
imessage	6%	124
matrix	<b>5%</b>	119

Telegram/Discord são os canais "core" — mais PRs e mais aceitos. Signal/Matrix/iMessage quase não passam.

### Top Authors (merged)

Author	Merges
<b>steipete</b>	<b>22</b>
0xRaini	20
mcaxtr	20
arosstale	18
mbelinky	18

**steipete = Peter (criador/maintainer)**. Os top contributors externos têm 18-20 merges.

### Additions/Deletions (amostra enriquecida, N=200)

Métrica	Valor
Mean additions	5,964 (distorcido por outliers)
<b>Median additions</b>	<b>89</b>
P90 additions	1,617
Max additions	752,543
Mean deletions	697
Mean changed files	103

**Mediana de 89 linhas adicionadas.** P90 em 1617 — confirma que 1000 LoC rule pega ~15-20% dos PRs.

## Greptile

- Presente em **muitas PRs** (324 reviews na amostra de 200)
- Formato: X files reviewed, Y comments — **sem score numérico 1-5**
- Bruno vai verificar e mandar exemplo do score
- Variáveis extraíveis: `greptile_files_reviewed` , `greptile_comment_count`

## O que pensei

1. **O viés de recência era perigoso.** Se tivéssemos estimado o logit com N=500, os coeficientes estariam errados — especialmente `trusted-contributor` (34% → 60% é uma inversão de sinal no modelo). A decisão de ampliar pra 2000 foi correta.
2. **Contributor type é o preditor mais forte**, mais que `size`. `maintainer=88%` é quase determinístico. Isso sugere que o logit vai ter um  $\beta_{\text{maintainer}}$  enorme. Implicação: o Clawkeeper precisa dizer "este PR foi submetido por um maintainer — merge quase certo" de forma transparente.
3. **Channel PRs têm merge rates baixos em geral** (5-18%). Hypothesis: PRs de channel são frequentemente de contribuidores one-shot que não conhecem o codebase profundamente. Se essa hipótese se confirmar, `is_channel_pr` x `author_merge_count` pode ter interação interessante.
4. **Mediana de 89 additions** = a maioria dos PRs são pequenos. O quality gate de 1000 LoC provavelmente rejeita top ~10-15%. Isso é feature, não bug — PRs enormes têm 13% merge rate.
5. **steipete como top contributor** — ele mergeia seus próprios PRs (maintainer privilege). Isso pode inflar o  $\beta_{\text{maintainer}}$ . Considerar excluir self-merges do treino, ou criar variável separada.

## Decisões tomadas

- Ampliei de 500 → 2000 PRs (validou que N=500 era insuficiente)
- Enriqueci amostra de 200 (suficiente pra estatísticas descritivas, logit usa as 2000)
- Mantive busca por Greptile score — se Bruno confirmar, faço scrape direcionado
- Plano DIFF atualizado em `plans/clawkeeper/PLAN-v4-DIFF.md`

## Riscos / Alertas

- **Self-merges do maintainer** podem enviesar o logit. Precisa de variável `is_self_merge` ou exclusão.
- **Additions/deletions só pra 200 PRs** — pro logit completo, preciso enriquecer as 2000. São ~~2000 API calls~~ (20-30 min com rate limiting).
- **Greptile score 1-5** não encontrado — se existir, é feature nova ou em PRs específicos. Aguardando Bruno.

## Próximo passo

1. Enriquecer 2000 PRs com additions/deletions (batch com gh CLI)
2. Começar pipeline Step 1-3 (ingest + signal extraction + categorization)
3. Estimar logit baseline com variáveis disponíveis

---

*Report gerado em sessão principal. Próximos via spawn Sonnet.*